

NLP ile Metin Sınıflandırma

Grup:Sentez

- Oğuzhan Yusuf Tozlu

Danışman:

- Dr. Öğretim Üyesi Şengül Bayrak



VERİ ÖN İŞLEME VE EDA

- Tıbbi sütunlardaki NaN → "bilgi_yok" ile dolduruldu.
- bilgi_yok tokeni sayesinde eksikliğin kendisi de bir sinyal haline geldi.

	Symptom	Test	Drug	Procedure
0	nöbet	bilgi_yok	bilgi_yok	bilgi_yok
1	afazi	bilgi_yok	bilgi_yok	bilgi_yok
2	zihinsel durum bozukluğu	bilgi_yok	bilgi_yok	bilgi_yok
3	bilgi_yok	bilgi_yok	bilgi_yok	bilgi_yok
4	bilgi_yok	bilgi_yok	bilgi_yok	bilgi_yok
5	bilgi_yok	protein belirteçleri	bilgi_yok	bilgi_yok
6	bilgi_yok	bilgi_yok	bilgi_yok	radasyon tedavisi
7	lezyon	MR	bilgi_yok	bilgi_yok
8	bilgi_yok	bilgi_yok	bilgi_yok	bilgi_yok
9	bilgi_yok	BT	bilgi_yok	bilgi_yok

VERİ ÖN İŞLEME VE EDA

- correct_prediction sütunlarındaki boş veriler temizlendi.
- Veri kaybı ihmal edilebilir düzeyde olan sütunlara işlem yapılmadı.

	Boş Sayısı	Boş %
model_prediction	5874	80.7
correct_prediction	1470	20.2
Intent	200	2.7
medical_entities	139	1.9
Emotion	2	0.0
diagnosis_stage	1	0.0
text	1	0.0
season	0	0.0
Procedure	0	0.0
Drug	0	0.0
Test	0	0.0
Symptom	0	0.0
episode	0	0.0
speaker	0	0.0
Organ	0	0.0
Sarcasm	0	0.0



	Boş Sayısı	Boş %
model_prediction	4594	79.0
medical_entities	128	2.2
Emotion	1	0.0
diagnosis_stage	1	0.0
text	1	0.0
season	0	0.0
speaker	0	0.0
episode	0	0.0
Intent	0	0.0
Procedure	0	0.0
Drug	0	0.0
Test	0	0.0
Symptom	0	0.0
Sarcasm	0	0.0
Organ	0	0.0
correct_prediction	0	0.0

VERİ ÖN İŞLEME VE EDA

- JSON verileri kontrol edilerek eksik sütunlar dolduruldu.
- Veriler hakkındaki bilgi artırılmış oldu.

Doldrulan satır sayısı (bilgi_yok → gerçek değer):

Symptom	214
Test	98
Drug	98
Procedure	126
Organ	88

Satır 93:

```
Drug      : bilgi_yok → "kızamık aşısı"  
medical_entities: [{"text":"bağışıklık sistemi","type":"Anatomy"}, {"text":"kızamık aşısı","type":"Drug"}]
```

Satır 106:

```
Symptom    : bilgi_yok → "düşük tansiyon"  
medical_entities: [{"text":"alerji","type":"Disease"}, {"text":"düşük tansiyon","type":"Symptom"}]
```

VERİ ÖN İŞLEME VE EDA

- correct_prediction sütunlarındaki benzersiz sütunlar listelendi.
- Sayısal değer ve anlamlı olmayan etiketler temizlenmek üzere tespit edildi.
- Ayrıca aynı sınıfların büyük-küçük harf farklılığından dolayı ("Hepatit C" ile "hepatit c") farklı özellikler olarak görüldüğü tespit edildi..

```
nörosistiserkozis 422
none 192
1 180
melanom 100
fosmet ile kontamine kıyafetlere bağlı organofosfat zehirlenmesi 69
Travma Sonrası Siringomyeli 65
amiloidoz 64
kimerizm 63
Şizofreni 62
radyasyon zehirlenmesi 61
Orak hücre taşıyıcılığı 61
Timoma 60
ekinokok 60
```

Sayısal değerler (180 satır):

```
correct_prediction
1      180
```

Anlamlı olmayan etiketler (217 satır):

```
correct_prediction
none      192
-         25
```


VERİ ÖN İŞLEME VE EDA

- Sayısal ve anlamsız değerler temizlendi.
- lower() ile büyük-küçük harf farklılıkları ortadan kalktı.
- Eşik: ≥ 50 örnek $\rightarrow$ 60 hastalık sınıfı kaldı
Kalan satır sayısı: 3648

```
hedef
nörosistiserkozis          422
melanom                    100
wilson hastalığı           90
fosmet ile kontamine kıyafetlere bağlı organofosfat zehirlenmesi 69
travma sonrası siringomyeli 65
amiloidoz                  64
kimerizm                   63
şizofreni                  62
radyasyon zehirlenmesi    61
orak hücre taşıyıcılığı   61
timoma                     60
ekinokok                   60
hepatit c                  57
kalp yetmezliği (ipecac fazlalığına bağlı) 56
testiküler kanser         55
kalıtsal hemorajik telenjiektazi 55
maternal ayna sendromu (ccam) 55
ekzojen testosteron maruziyeti 55
kontrast madde toksisitesi 55
...
yabancı cisim aspirasyonu 50
muckle-wells sendromu     50
plummer hastalığı         50
Name: count, dtype: int64
```

VERİ ÖN İŞLEME VE EDA

- Her satıra bağlam penceresi uygulandı.
- Tek başına anlam ifade etmeyen satırların komşu satırlarıyla bağlam kurulması amaçlandı.



[Satır 1] Orijinal (8 kelime):

Konuşma yetisini kaybetmiş, bebek gibi anlamsız sesler çıkarıyor.




[Satır 1] Bağlamlı (23 kelime):

29 yaşında bir kadın hasta; ilk nöbetini bir ay önce geçirmiş. Konuşma yetisini kaybetmiş, bebek gibi anlamsız sesler çıkarıyor. Mental durumu giderek kötüleşiyor.

ÖZELLİK MÜHENDİSLİĞİ

- **Temizleme:** HTML etiketleri ve özel karakterler kaldırıldı; **sayılar korundu** (yaş, dozaj, süre medikal bilgi taşır)
- **Tokenization:** Cümle boşluklardan kelime listesine bölündü.
- **Stop-words:** "önce", "sonra", "var", "yok" listede **YOK** — zaman ve varlık/yokluk bilgisi tıbbi teşhiste kritik
- **Lowercasing:** Tüm metin küçük harfe çevrildi.
- **Bigram** TF-IDF'te `ngram_range=(1,2)` ile "nöbet geçir", "ay önce" gibi kelime çiftleri özellik olarak eklendi.
- Alaycı cümlelerde her kelimeye "ALAY_" eki eklendi.
- Alaycı olmayan cümlelere 1.0, alaycılara 0.3 ağırlık atandı.

ÖZELLİK MÜHENDİSLİĞİ



ÖZELLİK BİRLEŞİMİ

- **X_text:** Karakterlerin konuşmalarından çıkarılan kelime/bigram ağırlıkları.
Modelin ana sinyal kaynağı — hangi kelimelerin hangi hastalıkla birlikte geçtiğini öğrenir.
- **X_tıbbi:** Symptom, Test, Drug, Procedure, Organ sütunlarından oluşan yapılandırılmış tıbbi terimler.
Diyalog gürültüsünden arındırılmış, saf tanı sinyali.
- **X_entity:** JSON formatındaki medical_entities sütunundan parse edilen varlıklar.
Tıbbi sütunlardan farklı olarak NLP ile otomatik çıkarılmış, daha zengin ve bağlamlı terimler içerir.
- **X_kategorik:** Metnin ne söylendiğini değil nasıl ve kim tarafından söylendiğini modele anlatır.
- **X_sayisal** — Sayısal Özellikler-df[['Sarcasm', 'season', 'episode']]
- **X_ent_counts** — Entity Sayıları (6 özellik)
n_Symptom, n_Test, n_Drug, n_Procedure, n_Anatomy, n_total

Özellik grupları:

X_text	:	(3648, 5000)
X_tibbi	:	(3648, 3000)
X_entity	:	(3648, 3000)
X_kategorik	:	(3648, 151)
X_sayisal	:	(3648, 3)
X_ent_counts	:	(3648, 6)
TOPLAM	:	(3648, 11160)


MODEL EĞİTİMİ

- test_size=0.2
- random_state=42
- stratify=y → Her sınıfın train/test oranı korundu.
- class_weight='balanced' → Az örnekli sınıflara yüksek ağırlık
- Üç farklı eğitim yapıldı.


```
Eğitim seti: (2918, 11160)
Test seti   : (730, 11160)
```

```
modeller = {
    'Logistic Regression': LogisticRegression(
        max_iter=1000, random_state=42,
        class_weight='balanced',
        C=1.0
    ),
    'LinearSVC': LinearSVC(
        max_iter=2000, random_state=42,
        class_weight='balanced',
        C=1.0
    ),
    'Random Forest': RandomForestClassifier(
        n_estimators=200, random_state=42, n_jobs=-1,
        class_weight='balanced'
    ),
}
```

SONUÇLAR



SONUÇLAR



Dinlediğiniz İçin Teşekkür Ederim.